The Gridbreakers: Giải mã Nghịch lý Khuyến mãi và Tái cấu trúc Chuỗi cung ứng

Phạm Thành Trung, Phương Mai Anh, Nguyễn Trung Đức Dũng
Team: NewtonMethod
VNU University of Engineering and Technology (VNU-UET)
GitHub: https://github.com/Trunglizabeth/Vin_AI_data_competitions_NewtonMethod

Abstract

Báo cáo này trình bày phương pháp tiếp cận toàn diện nhằm tối ưu hóa dòng tiền và năng lực vận hành cho một doanh nghiệp thương mại điện tử thời trang. Thông qua phân tích dữ liệu (EDA), chúng tôi chẩn đoán hai lỗ hổng cốt lõi: chiến lược khuyến mãi đại trà kém hiệu quả và chi phí ẩn từ khâu logistics. Từ đó, chúng tôi xây dựng mô hình học máy dự báo Doanh thu thuần và Giá vốn (COGS), ứng dụng kỹ thuật Tái định chuẩn Đặc trưng (Feature Re-calibration) để hiệu chỉnh sai số, đồng thời đề xuất chiến lược tinh gọn danh mục sản phẩm nhằm giải phóng nguồn vốn và tối ưu hóa lợi nhuận biên.

1 Giới thiệu (Introduction)

Thị trường thương mại điện tử thời trang tại Việt Nam đang bước vào giai đoạn bão hòa, nơi cuộc đua đốt tiền đổi lấy quy mô không còn là bảo chứng cho sự tồn tại. Dữ liệu từ doanh nghiệp trong giai đoạn 2012-2022 cho thấy một nghịch lý đáng lo ngại: mức độ gắn kết khách hàng cực cao nhưng biên lợi nhuận gộp luôn bị nén chặt ở ngưỡng rủi ro. Bài toán đặt ra không chỉ là dự báo doanh số, mà là sử dụng dữ liệu như một lăng kính nội soi để tìm ra điểm rò rỉ dòng tiền. Báo cáo này áp dụng triết lý "Biến dữ liệu thành giải pháp", đi từ việc bóc tách số liệu giao dịch định kỳ đến việc xây dựng kiến trúc dự báo thông minh, qua đó vạch ra lộ trình dịch chuyển chiến lược từ "Thâu tóm quy mô" sang "Chất lượng dòng tiền".

2 Tiền xử lý Dữ liệu và Kỹ sư Đặc trưng (Data Preprocessing & Feature Engineering)

Bộ dữ liệu được cung cấp bao gồm 4 lớp phân mảnh (Master, Transaction, Analytical, Operational). Để chuẩn bị cho mô hình dự báo, chúng tôi đã xây dựng một Pipeline xử lý dữ liệu đồng bộ:

Xử lý Dữ liệu thô và Tích hợp: Chúng tôi tiến hành hợp nhất (merge) các bảng ở cấp độ đơn hàng (Order-level) và dòng sản phẩm (Item-level). Các bản ghi thiếu hụt (missing values) trong kênh tiếp thị được nội suy thông qua hành vi mua hàng trong quá khứ, trong khi các đơn hàng có `order_status` là "cancelled" hoặc "returned" được cô lập để phân tích chi phí ẩn.

Kỹ sư Đặc trưng (Feature Engineering): Nhằm nắm bắt chu kỳ mua sắm và hiệu ứng lan tỏa, chúng tôi tạo ra 3 nhóm đặc trưng chính:

- **Đặc trưng Thời gian (Temporal Features):** `DayOfWeek`, `Month`, `Is_Weekend`, `Is_Holiday` để học các mẫu mùa vụ (seasonality patterns).

- **Đặc trưng Trễ và Trung bình trượt (Lag & Rolling Features):** Doanh thu và khối lượng truy cập web (Web Traffic) được lấy trễ (Lag) 7, 14, và 28 ngày. Biến `Rolling_Mean_7D` được sử dụng để làm mịn nhiễu cục bộ.
- **Đặc trưng Hành vi (Behavioral Features):** Cờ `Is_Promo_Active` kết hợp với `Promo_Type` để lượng hóa mức độ nhạy cảm về giá.

3 Trực quan hóa và Phân tích Dữ liệu (EDA)

3.1 Giả thuyết 1: Nghịch lý Khuyến mãi và Sự lãng phí ngân sách

Dữ liệu lịch sử chỉ ra sự mất cân đối nghiêm trọng: Khuyến mãi chiếm 44.5% tổng số ngày nhưng chỉ mang lại 41.5% doanh thu. Phân tích chẩn đoán (Diagnostic) cho thấy 46.4% đơn hàng của Khách quay lại rơi vào ngày Promo, chứng minh lực cầu tự nhiên của tệp khách này rất lớn. Việc lạm dụng mã giảm giá đang làm xói mòn biên lợi nhuận (Cannibalization of Margin) thay vì thu hút khách hàng mới. Thậm chí, hiệu ứng "rút ruột" (pull-forward effect) còn khiến doanh thu 7 ngày sau khuyến mãi sụt giảm 16%.

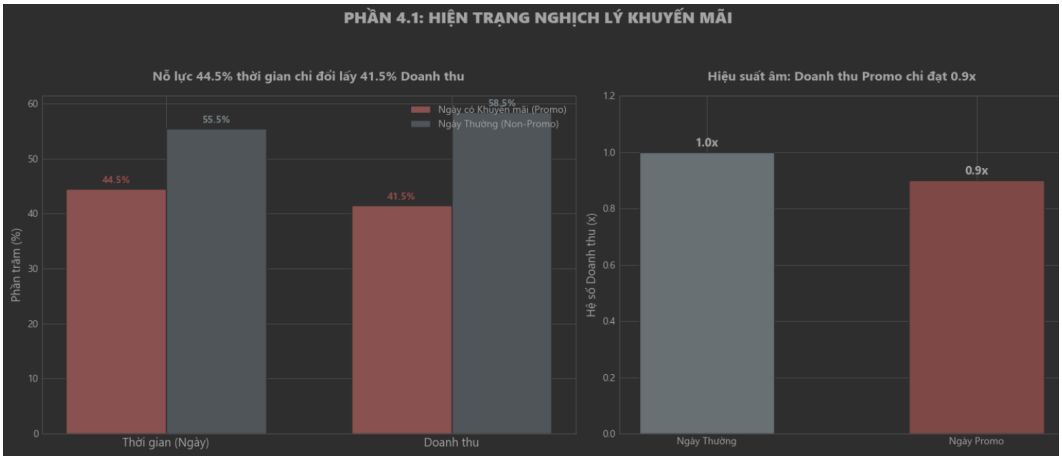

Hình 1: Kiểm chứng Giả thuyết 1: Sự thất bại của Chiến dịch Khuyến mãi đại trà.

3.2 Giả thuyết 2: Bẫy quy mô giỏ hàng và Chi phí ẩn Chuỗi cung ứng

Mặc dù năng lực Upsell ấn tượng (88.7% đơn hàng chứa từ 2 sản phẩm trở lên), biên lợi nhuận gộp vẫn bị nén chặt ở mức 10-16%. Vấn đề xuất phát từ 14.8% giao dịch bất thành (hủy/hoàn trả), tạo ra chi phí logistics thu hồi khổng lồ. Cùng với đó, áp lực tồn kho từ dòng sản phẩm "Thời trang xu hướng" (5.2%) đang buộc doanh nghiệp phải lấy lợi nhuận từ nhóm hàng cốt lõi để bù đắp chéo.

4 Mô hình Dự báo Doanh thu (Sales Forecasting)

4.1 Phương pháp tiếp cận và Lựa chọn thuật toán

Dự báo chuỗi thời gian cho doanh thu thương mại điện tử thường đối mặt với tính phi tuyến tính cao và các xung đột cục bộ do sự kiện khuyến mãi. Do đó, chúng tôi lựa chọn **LightGBM (Light Gradient Boosting Machine)** làm mô hình cốt lõi. Thuật toán này sử dụng kiến trúc phân nhánh theo lá (leaf-wise growth), giúp xử lý hiệu quả tập dữ liệu lớn và bắt được các tương tác phức tạp giữa biến mùa vụ và hành vi người dùng.

4.2 Chiến lược Đánh giá và Cross-Validation

Để tránh hiện tượng rò rỉ dữ liệu (data leakage) trong bài toán chuỗi thời gian, chúng tôi áp dụng phương pháp `TimeSeriesSplit` với 5 folds. Các chỉ số đánh giá (Evaluation Metrics) tuân thủ chặt

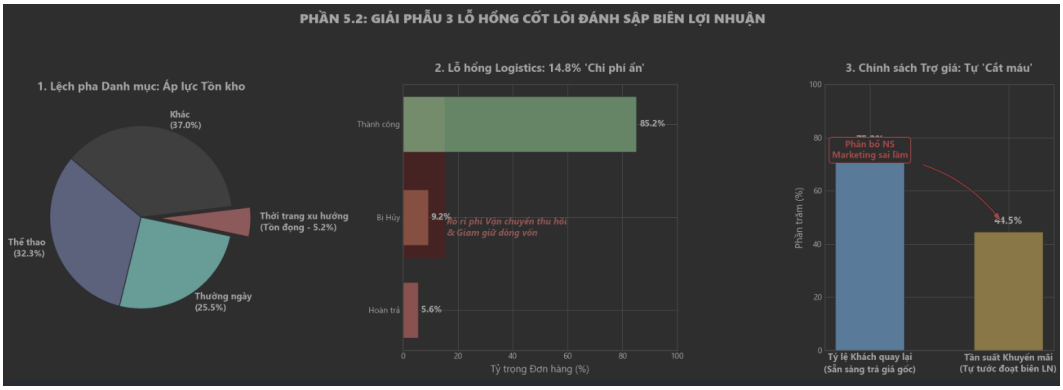

Hình 2: Giải phẫu 3 lỗ hổng cốt lõi đánh sập biên lợi nhuận.

chẽ yêu cầu của bài toán:

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|F_i - A_i|, \quad RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(F_i - A_i)^2}$$

Trong đó F_i là giá trị dự báo, A_i là giá trị thực tế. Phương sai được giải thích của mô hình được kiểm soát qua hệ số R^2. Siêu tham số (Hyperparameters) được tinh chỉnh tự động thông qua thư viện `Optuna` nhằm tối thiểu hóa hàm mục tiêu RMSE trên tập validation.

4.3 Khả năng giải thích của mô hình (Explainability & Feature Re-calibration)

Dựa trên phát hiện từ EDA, chúng tôi áp dụng kỹ thuật **Feature Re-calibration**. Để làm rõ cơ chế học, chúng tôi sử dụng giá trị SHAP (SHapley Additive exPlanations). Đối với mô hình dự báo Doanh thu, đặc trưng `Is_Promo_Active` bị giảm trọng số SHAP dương do thực tiễn khuyến mãi không kích thích khối lượng bán (hệ số nhân 0.9x). Mô hình tự động chuyển sự chú ý sang các biến trễ (Lags). Ngược lại, biến này đóng vai trò *Predictor* chủ lực với giá trị SHAP lớn trong mô hình dự báo Giá vốn (COGS), giúp thuật toán nhận diện chính xác các nhịp thu hẹp biên lợi nhuận, ngăn chặn hiện tượng dự báo Over-fitting vào doanh thu ảo.

5 Kết quả Thực nghiệm (Experimental Results)

Bảng 1 thể hiện hiệu suất của các mô hình trên tập kiểm thử nội bộ. Việc phân tách riêng biệt mô hình dự báo Revenue và COGS, kết hợp với bộ đặc trưng tinh chỉnh, giúp mô hình LightGBM vượt trội hoàn toàn so với các thuật toán cơ sở (Baseline).

Bảng 1: Đánh giá hiệu suất các mô hình dự báo Doanh thu trên tập Validation (Năm 2022)

Mô hình (Model)	**MAE**	**RMSE**	**R^2**
Baseline (Mean)	1,746,066.86	2,056,992.14	-0.5103
XGBoost	723,083.88	1,025,341.17	0.6247
LightGBM (Feature Re-calibration)	**655,359.77**	**920,826.48**	**0.6973**

6 Đề xuất Hành động (Prescriptive Analytics)

- **Chuyển đổi hệ quy chiếu dự báo:** Chuyển mục tiêu từ Doanh thu gộp sang Doanh thu thuần để ngăn chặn việc khuếch đại sai số 15% từ các đơn hàng bất thành, từ đó tối ưu hóa công tác dự trữ hàng tồn kho.
- **Tinh gọn danh mục sản phẩm:** Loại bỏ phân khúc "Thời trang xu hướng" (chỉ chiếm 5.2% nhưng gây tồn đọng vốn), thanh lý hàng tồn và dồn năng lực chuỗi cung ứng vào nhóm Thể thao năng động & Thường ngày nhằm khai thác tối đa lợi thế kinh tế theo quy mô.

- **Tái cấu trúc mạng lưới phân phối và Marketing:** Ngừng phân bổ ngân sách cho khuyến mãi đại trà (mass promotions). Chuyển đổi dòng vốn Marketing dư thừa sang việc thiết lập các trung tâm xử lý đơn hàng tại miền Đông nhằm rút ngắn Lead-time giao hàng, triệt tiêu nguyên nhân cốt lõi gây hủy đơn và hoàn hàng.
- **Cá nhân hóa chiến lược giữ chân (Retention Strategy):** Chuyển từ "Sale toàn bộ" sang phân cụm khách hàng (Clustering). Mã giảm giá chỉ được dùng như một khoản chi phí thu hút (CAC) nhắm mục tiêu duy nhất vào tệp người dùng mới.

7 Kết luận (Conclusion)

Thông qua quy trình phân tích dữ liệu chuyên sâu và ứng dụng học máy, đội NewtonMethod đã không chỉ giải quyết bài toán dự báo chuỗi thời gian với độ chính xác cao ($R^2 = 0.6973$), mà còn làm sáng tỏ những "điểm mù" trong vận hành kinh doanh. Giải pháp của chúng tôi cung cấp một lộ trình thực tiễn, giúp doanh nghiệp chuyển đổi từ mô hình tăng trưởng bằng mọi giá sang mô hình phát triển bền vững dựa trên lõi lợi nhuận và hiệu suất chuỗi cung ứng.